HSMS Proofer · Prontuario para añadir etiquetas de lengua

Documento interno de mantenimiento · 27 de octubre de 2026

Objetivo: disponer de una guía breve, segura y reproducible para incorporar, solo cuando sea necesario, nuevas etiquetas como RUS (ruso). Este documento no añade ninguna etiqueta al programa.

1. Fichero y funciones que hay que revisar

Fichero: `validator_structure.R`. En primer lugar, localizar `hsms_structural_tag_catalog()`. Después, localizar `check_insertions_deletions_do_not_cross_textual_containers()` y su vector `textual_containers`.

Conviene buscar también en todo el proyecto las listas explícitas de códigos de lengua (por ejemplo `LAT`, `CHN`, `JPN`), por si otra función incluye enumeraciones fijas. En RStudio: Cmd + Shift + F.

2. Catálogo: añadir una fila coherente en TODOS los vectores

El catálogo está construido mediante `data.frame()` con columnas definidas como vectores paralelos. Cada etiqueta necesita exactamente un valor en cada columna y en el mismo orden. La manera más fácil es añadir la nueva lengua inmediatamente antes de RMK en todos ellos.

Columna	Valor para una lengua nueva
tag	"RUS" (ejemplo, no incorporado)
position	1
contents	2
delimiter	"."
allows_vector_prefix	FALSE
allows_vector_suffix	FALSE
can_span_lines	TRUE
can_continue	TRUE
numbered	FALSE
tag_group	"language"
allows_empty	FALSE
special_rule	"none"
special_processing	0

Ejemplo de inserción de etiquetas en la lista `tag`:

```
"LAT", "PRT", "PRV", "CHN", "JPN", "RUS",
"RMK"
```

En las otras columnas, se añade el valor correspondiente a RUS en la misma posición. En las columnas con comentarios individuales (como `allows_empty` y `special_rule`), añadir también su comentario `# RUS`.

3. Contenedores textuales

En `check_insertions_deletions_do_not_cross_textual_containers()`, incorporar el código a `textual_containers`, junto a las demás etiquetas de lengua:

```
textual_containers <- c(
  "CB", "CW", "DIAG", "HD", "MIN", "RUB", "SYMB", "SG",
  # ... otras etiquetas de lengua ...
  "LAT", "PRT", "PRV", "CHN", "JPN", "RUS"
)
```

Importante: no eliminar los códigos existentes y mantener fuera de esta lista `AD` y `GL` si la versión actual los excluye expresamente para evitar falsos positivos con mnemónicos internos.

4. Comprobación inmediata del catálogo

```
source("validator_structure.R", encoding = "UTF-8")
catalog <- hsms_structural_tag_catalog()
subset(catalog, tag %in% c("LAT", "CHN", "JPN", "RUS"))
stopifnot(!anyDuplicated(catalog$tag))
stopifnot("RUS" %in% catalog$tag)
```

Las propiedades de RUS deben coincidir con las de LAT, CHN y JPN. No mantener fijo el número 33 en las comprobaciones: crece cada vez que se incorpora una etiqueta.

5. Pruebas de validación positivas y negativas

Tras incorporar efectivamente la nueva etiqueta, recargar los módulos de la aplicación y ejecutar estas pruebas con un nombre de fichero válido.

```
source("validator_core.R", encoding = "UTF-8")
source("validator_structure.R", encoding = "UTF-8")
source("validator_editorial.R", encoding = "UTF-8")
source("validator_main.R", encoding = "UTF-8")

writeLines(c("[fol. 1r]", "{CB1.",
             "{RUS. texto ruso}", "texto}"),
           "TEXT.RUS.txt", useBytes = TRUE)
res <- validate_file("TEXT.RUS.txt", "TEXT.RUS.txt")
res$df
```

Esperado: ninguna incidencia para `{RUS. texto ruso}`.

```
writeLines(c("[fol. 1r]", "{CB1.",
             "{RUS.}", "texto}"),
           "TEXT.RUE.txt", useBytes = TRUE)
res_empty <- validate_file("TEXT.RUE.txt", "TEXT.RUE.txt")
res_empty$df
```

Esperado: una incidencia de etiqueta de lengua vacía por `{RUS.}`. Si se detecta como etiqueta desconocida, revisar el catálogo y las listas explícitas.

6. Si aparece un error de longitud

El mensaje `arguments imply differing number of rows: 34, 33` significa que algún vector paralelo tiene menos elementos. No añadir valores al azar. Contar y alinear las columnas de la función. En la incorporación de CHN y JPN, el vector olvidado fue `numbered`.

En una revisión manual, recorrer cada vector desde `tag` hasta `special_processing`; comprobar que el valor nuevo está antes del de RMK. En particular: `FALSE` en `numbered`, `allows_empty` y vectores; `TRUE` en `can_span_lines` y `can_continue`.

7. Cierre del cambio

Solo tras superar las pruebas: actualizar `NEWS.md` y hacer un commit independiente. Ejemplo futuro:

```
NEWS.md: Added support for the RUS (Russian) language
mnemonic, including detection of empty language tags.

Commit: Add RUS language mnemonic
```

Regla de oro: el editor decide cuándo hace falta una nueva lengua; Proofer solo la reconoce y aplica las mismas comprobaciones que a las demás. No crear RUS hasta disponer de la necesidad editorial correspondiente.